

Linear models: recursive least squares (RLS)

Standard least squares: $f(\mathbf{x}_n) = \mathbf{x}_n^\top \mathbf{w}$, loss function $(f(\mathbf{x}_n) - y_n)^2$, covariance matrix $\Sigma_n = X^\top X$, $X \in \mathbb{R}^{n \times d}$. The solution for $f^*(\mathbf{x}) = \mathbf{x}^\top \mathbf{w}^*$ is

$$\mathbf{w}^* = (X^\top X)^{-1} X^\top y = \Sigma_n^{-1} \sum_{i=1}^n \mathbf{x}_i y_i$$

RLS: based on the matrix inversion lemma:

Initialize $\mathbf{w}_0 = 0 \in \mathbb{R}^d$, and $\Gamma_0 = I \in \mathbb{R}^{d \times d}$.

Iteration:

$$\begin{aligned}\Gamma_n &= \Gamma_{n-1} - \frac{\Gamma_{n-1} \mathbf{x}_n \mathbf{x}_n^\top \Gamma_{n-1}}{1 + \mathbf{x}_n^\top \Gamma_{n-1} \mathbf{x}_n} \\ \mathbf{w}_n &= \mathbf{w}_{n-1} - \Gamma_n \mathbf{x}_n (\mathbf{x}_n^\top \mathbf{w}_{n-1} - y_n)\end{aligned}$$

It can be shown that $\Gamma_n = \Sigma_n^{-1}$.

The regularized version is obtained as usual by introducing a regularizer in the loss function, $\sum_{i=1}^n (\mathbf{w}^\top \mathbf{x}_i - y_i)^2 + \lambda \|\mathbf{w}\|_2^2$, and starting from $\Gamma_0 = (I + \lambda)^{-1}$. This converges to $\Gamma_n = (\Sigma_n + \lambda I)^{-1}$.

Explicación — Diapositiva 1

Tema: Linear Models: Recursive Least Squares (RLS)

Síntesis:

Esta diapositiva explica cómo se puede ajustar un modelo lineal de manera eficiente utilizando el método de los mínimos cuadrados recursivos (RLS). Se enfoca en cómo este enfoque permite actualizar continuamente los pesos del modelo con nuevas observaciones, evitando la necesidad de recalcularlo desde cero cada vez que se añade una nueva entrada.

Explicación:

Modelo Lineal y Mínimos Cuadrados Clásicos:

El modelo lineal se define como $f(x_n) = x_n^T w$, donde x_n son las características de entrada y w son los pesos o coeficientes del modelo. El objetivo es minimizar la función de pérdida $(f(x_n) - y_n)^2$, donde y_n es la salida real. La solución clásica implica calcular directamente los pesos w^* que minimizan esta función, utilizando la matriz de covarianza $\Sigma_n = X^T X$.

Método de los Mínimos Cuadrados Recursivos (RLS):

El método de los mínimos cuadrados recursivos es una versión más eficiente del método clásico. En lugar de reiniciar el proceso de optimización desde cero con cada nueva observación, RLS utiliza una matriz de confianza Γ_n que se actualiza con cada nueva entrada. Esta matriz de confianza mide la incertidumbre en la estimación actual y determina cuánto debe ajustarse el modelo cuando se introduce una nueva observación.

Matriz de Confianza y Regularización:

La matriz de confianza Γ_n se inicializa como $\Gamma_0 = I$ (matriz identidad), lo que indica una confianza inicial en la precisión de la estimación. Con cada nueva observación x_i y su correspondiente salida y_i , se actualiza la matriz de confianza según la fórmula $\Gamma_{n+1} = (\Sigma_n + \lambda I)^{-1}$, donde λ es un parámetro de regularización que controla la cantidad de regularización aplicada.

Iteración y Actualización:

En cada iteración, se actualiza la matriz de confianza Γ_n utilizando la matriz de covarianza $\Sigma_n = X^T X$. Esto permite que el modelo se adapte gradualmente a nuevos datos sin necesidad de recalcular completamente los pesos. La regularización adicional se introduce mediante la función de pérdida $\sum_{i=1}^n (w^T x_i - y_i)^2 + \lambda \|w\|_2^2$, donde λ controla la penalización de los pesos más grandes.

Convergencia y Eficiencia:

El método de los mínimos cuadrados recursivos converge a la solución óptima w^* mientras se introducen nuevas observaciones. Esta convergencia es más eficiente computacionalmente que

el método clásico, especialmente en contextos donde se manejan grandes conjuntos de datos o se requiere adaptabilidad a cambios en tiempo real.

En resumen, el método de los mínimos cuadrados recursivos proporciona una forma eficiente de ajustar modelos lineales, permitiendo una actualización continua y eficiente de los pesos con nuevas observaciones, lo que resulta en una mejora en la precisión y la eficiencia computacional.

Stochastic Gradient Descent

Instead of updating w_n using

$$w_n = w_{n-1} - \Gamma_n x_n (x_n^\top w_{n-1} - y_n)$$

use gradient descent:

$$w_n = w_{n-1} - \alpha_n \nabla V(f(x_n), y_n)$$

where α_n is the learning rate, and $V(f(x_i), y_i)$ a convex, differentiable loss function.

The learning can be done in batches, and the order of the input samples can be stochastic or deterministic.

Explicación — Diapositiva 2

Tema: Descenso del Gradiente Estocástico (Stochastic Gradient Descent)

Síntesis:

Este slide explica cómo implementar el descenso del gradiente estocástico como alternativa al descenso del gradiente tradicional, enfatizando la importancia de la tasa de aprendizaje y la función de pérdida convexa diferenciable. También aborda cómo el proceso de aprendizaje puede ser realizado en lotes y cómo la ordenación de las muestras de entrada puede ser aleatoria o determinista.

Explicación:

El descenso del gradiente estocástico (SGD) es una variante del método más común de optimización en aprendizaje automático, el descenso del gradiente (GD). En lugar de actualizar la variable de peso w_n utilizando el gradiente calculado sobre todos los datos de entrenamiento (como en el descenso del gradiente tradicional), el SGD realiza actualizaciones más frecuentes y menos costosas.

En el slide se menciona que la tasa de aprendizaje, representada por α_n , es crucial para controlar la velocidad de convergencia del algoritmo. La tasa de aprendizaje debe ser adecuada para evitar oscilaciones innecesarias y asegurar que el algoritmo no se detenga demasiado pronto.

La función de pérdida $V(f(x_i), y_i)$ es descrita como convexa y diferenciable, lo que significa que tiene una única mínima global y su gradiente existe y es continuo en ese punto. Esta propiedad es importante porque garantiza que el algoritmo converge a la solución óptima si se utiliza correctamente.

El slide también introduce la idea de realizar el descenso del gradiente en lotes, también conocido como mini-batch. En lugar de utilizar todos los datos de entrenamiento para calcular el gradiente en cada iteración, se seleccionan un número pequeño de muestras (lotes) de manera aleatoria. Esto permite un balance entre la precisión y la eficiencia computacional.

Finalmente, el slide destaca la importancia de la ordenación de las muestras de entrada. Puede ser realizada de dos maneras: de manera aleatoria (estocástica) o en un orden determinista. La ordenación estocástica implica que cada muestra de entrada se selecciona para el lote de manera independiente y aleatoria, mientras que la ordenación determinista implica que se siguen los datos en el mismo orden en cada iteración. La dependencia de la ordenación puede afectar la convergencia del algoritmo, por lo que es importante considerarla en el diseño del algoritmo.

En resumen, el descenso del gradiente estocástico es una técnica poderosa que combina la flexibilidad de la mini-batch con la eficiencia de la ordenación aleatoria, proporcionando una alternativa eficiente al descenso del gradiente tradicional.

Kernel methods: KRR (aka LS-SVM)

In kernel methods, the predictor at the n -th step has the form

$$f_n(\mathbf{x}) = \langle \mathbf{w}_n, \mathbf{x} \rangle = \sum_{k=1}^n (\alpha_n)_k \langle \mathbf{x}_k, \mathbf{x} \rangle = \sum_{k=1}^n (\alpha_n)_k K(\mathbf{x}_k, \mathbf{x})$$

where $\mathbf{w}_n = X_n^\top \alpha_n$, and $\alpha_n = (K(\mathbf{x}_n, \mathbf{x}_n) + \lambda I)^{-1} \mathbf{y}_n$.

Naive kernel regression: weights are recursively obtained using

$$\begin{aligned}\alpha_o &= 0 \\ (\alpha_n)_i &= (\alpha_{n-1})_i, \quad i = 1, \dots, n-1 \\ (\alpha_n)_n &= \gamma_n \left(y_n - \sum_{k=1}^{n-1} (\alpha_{n-1})_k K(\mathbf{x}_k, \mathbf{x}_n) \right)\end{aligned}$$

begin γ_n is the learning rate.

Explicación — Diapositiva 3

Tema: Kernel Methods: KRR (Least Squares Support Vector Machine)

Síntesis:

En esta diapositiva se explica cómo se calculan los pesos recursivamente en el método de regresión con kernels (KRR), también conocido como Least Squares Support Vector Machine (LS-SVM). Se discute cómo estos pesos se obtienen a partir de una fórmula matemática específica y cómo se relacionan con la regresión con kernels.

Explicación:

El tema principal de esta diapositiva es el método de regresión con kernels (Kernel Regression, KRR), que es una técnica de aprendizaje no supervisado utilizada para predecir valores continuos en base a datos de entrada. Este método se implementa comúnmente mediante el uso de un modelo llamado Least Squares Support Vector Machine (LS-SVM).

En el contexto de KRR, el predictor en el paso n -ésimo tiene la siguiente forma: $w_n = X_n^{\text{top}} \alpha_n$, donde α_n es un vector de pesos que se determina a partir de la siguiente ecuación: $\alpha_n = (K(x_n, x_n) + \lambda I)^{-1} y_n$. Aquí, $K(x_n, x_n)$ representa el kernel aplicado al punto de entrada x_n , λ es un parámetro de regularización que controla la complejidad del modelo, y y_n son los valores de salida correspondientes a los puntos de entrada x_n .

Es importante notar que el término $K(x_n, x_n) + \lambda I$ se conoce como la matriz de Gram modificada, que incorpora una penalización adicional para evitar sobreajuste. Esta penalización se realiza a través del término λI , donde I es la matriz identidad.

La regresión con kernels es una extensión de la regresión lineal que permite modelar relaciones no lineales entre las variables de entrada y la variable de salida. Para hacer esto, utiliza funciones de kernel que transforman los datos en un espacio de alta dimensión, donde es posible encontrar una relación lineal entre ellos.

Una característica particular de KRR es que los pesos α_n se obtienen recursivamente. Esto significa que en cada paso, se actualiza el vector de pesos α_n basándose en los valores anteriores. El término "naive kernel regression" se refiere a este proceso de cálculo recursivo de los pesos, donde cada paso depende de los resultados obtenidos en los pasos anteriores.

En resumen, la diapositiva explica cómo se calculan los pesos en el método de regresión con kernels, cómo se relacionan con la matriz de Gram modificada y cómo se utilizan para realizar

predicciones. También destaca la importancia de la recursividad en el cálculo de estos pesos y cómo se puede interpretar la regresión con kernels como una extensión de la regresión lineal que permite modelar relaciones no lineales.