


MINIMUM COVARIANCE DETERMINANT (MCD)

- Estimación robusta de la localización y la dispersión.
- Menos sensible que métodos que utilizan la media y la matriz de covarianza.
- Idea: Determinante de la covarianza como medida de la dispersión de los datos (Volumen de los datos).
- Encuentra el subconjunto de datos que minimiza el determinante de la covarianza.
- Una posibilidad es elegir diferentes subconjuntos de datos aleatoriamente y elegir el que minimice el determinante.
- Especialmente interesante cuando los datos tienen distribuciones elípticas...



**DETERMINANTE
PEQUEÑO: BAJA
VARIABILIDAD
CONJUNTA; LOS DATOS
ESTÁN CONCENTRADOS**

**DETERMINANTE
GRANDE: ALTA
VARIABILIDAD
CONJUNTA; LOS DATOS
ESTÁN DISPERSOS**

Explicación — Diapositiva 1

Tema: Minimum Covariance Determinant (MCD) - Estimación robusta de la localización y la dispersión.

Síntesis:

El MCD es una técnica estadística que proporciona una estimación robusta de la localización y la dispersión de los datos, siendo menos sensible a valores atípicos o outliers comparado con métodos que utilizan la media y la matriz de covarianza.

Explicación:

Conceptos Básicos:

El MCD se basa en la idea de encontrar el subconjunto de datos que minimiza el determinante de la covarianza, que es una medida de la dispersión de los datos. Esta covarianza se relaciona con el volumen de los datos, similar a cómo la varianza se relaciona con la dispersión de los datos en una distribución normal.

Proceso de Estimación:

Para implementar el MCD, se selecciona un subconjunto de datos aleatorio. Este subconjunto debe ser suficientemente grande para representar adecuadamente la distribución de los datos. El objetivo es encontrar el subconjunto que minimice el determinante de la covarianza, lo que se traduce en una estimación más robusta de la dispersión.

Detalles Técnicos:

El proceso de selección del subconjunto de datos se realiza de varias maneras. Una opción es elegir subconjuntos aleatorios y elegir el que minimice el determinante de la covarianza. Otro método es usar una discretización de los datos, donde se divide el espacio de los datos en celdas y se selecciona el subconjunto de celdas que minimice el determinante de la covarianza.

Robustez:

El MCD es especialmente útil cuando los datos presentan distribuciones elípticas, es decir, cuando los datos se agrupan en formas elípticas. En estos casos, el MCD puede proporcionar una estimación más precisa y menos influenciada por outliers o valores atípicos.

Comparación con otros Métodos:

El MCD es menos sensible a outliers y valores atípicos, lo que lo hace más robusto que métodos que utilizan la media y la matriz de covarianza. Sin embargo, aunque es menos sensible a outliers, no significa que sea inmune a ellos; simplemente minimiza su impacto en la estimación.

Aplicaciones:

El MCD se utiliza en diversas áreas, incluyendo la minería de datos, la inferencia estadística y la clasificación de datos. Su capacidad para manejar datos con distribuciones elípticas lo hace particularmente útil en situaciones donde los datos pueden contener valores atípicos.

Ejemplo de Implementación:

El audio menciona cómo el MCD puede ser implementado utilizando la distancia de los vecinos más cercanos. Se selecciona un subconjunto de datos aleatorio y se calcula el determinante de la covarianza para cada subconjunto. El subconjunto que minimiza este determinante se considera la estimación del MCD.

Conclusión:

El MCD es una herramienta robusta para estimar la localización y la dispersión de los datos, especialmente cuando estos datos presentan distribuciones elípticas. Aunque es menos sensible a outliers, sigue siendo importante considerar la presencia de estos valores atípicos en el análisis de los datos.

MINIMUM COVARIANCE DETERMINANT (MCD)

- Encuentra el subconjunto de datos que minimiza el determinante de la covarianza.
- Primera aproximación....

$$\hat{\mu}_{MCD} = \frac{\sum_{i=1}^n W(d_i^2) x_i}{\sum_{i=1}^n W(d_i^2)}$$



$$\hat{\Sigma}_{MCD} = c_1 \frac{1}{n} \sum_{i=1}^n W(d_i^2) (x_i - \hat{\mu}_{MCD}) (x_i - \hat{\mu}_{MCD})^t$$

$$d_i = \sqrt{(x - \hat{\mu}_0)^t \hat{\Sigma}_0^{-1} (x - \hat{\mu}_0)}$$

$$W(d^2) = I(d^2 \leq \chi_{p,0.975}^2)$$

DETERMINANTE
PEQUEÑO: BAJA
VARIABILIDAD
CONJUNTA; LOS DATOS
ESTÁN CONCENTRADOS

CONSIDERA SOLO
LOS DATOS QUE
CUMPLEN UNA
CONDICIÓN DE LA
DISTANCIA



Explicación — Diapositiva 2

Tema: Minimum Covariance Determinant (MCD) - Encuentra el subconjunto de datos que minimiza el determinante de la covarianza.

Síntesis:

El MCD es un método estadístico que busca identificar un subconjunto de datos que tiene la menor covarianza posible, lo que significa que estos datos son menos variados entre sí. Este proceso ayuda a reducir la incertidumbre en el análisis de los datos.

Explicación:

Concepto Básico:

El MCD es un enfoque para encontrar un subconjunto de datos que minimice el determinante de la matriz de covarianza. La matriz de covarianza mide cómo cambian los datos entre sí. Un determinante pequeño indica que los datos están más estables o menos dispersos, lo que puede ser beneficioso para el análisis.

Subconjunto de Datos:

El objetivo principal del MCD es identificar un subconjunto de datos que represente mejor la estructura de los datos originales. Este subconjunto debe ser lo más representativo posible de toda la muestra de datos.

Condición de la Distancia:

Para seleccionar este subconjunto, se consideran las distancias entre los puntos de datos. Se toman los datos que cumplen con ciertas condiciones de distancia, generalmente basadas en la mediana o la media de las distancias a sus vecinos más cercanos (k-Nearest Neighbors, KNN). Estas condiciones aseguran que los datos elegidos no sean extremadamente lejanos unos de otros, evitando así que se seleccione un subconjunto que sea demasiado heterogéneo.

Primera Aproximación:

La primera aproximación al MCD implica calcular la covarianza para todos los datos y luego seleccionar un subconjunto que tenga el determinante de la covarianza más pequeño. Esto se hace para reducir la variabilidad entre los datos, lo que puede mejorar la precisión del análisis posterior.

Aplicación de MCD:

El MCD es especialmente útil cuando se tienen datos aleatorios y se necesita identificar un subconjunto que refleje mejor la estructura de los datos sin incluir demasiados valores atípicos. Este método es ampliamente utilizado en análisis multivariante y en la identificación de outliers en grandes conjuntos de datos.

En resumen, el MCD es un enfoque poderoso para seleccionar un subconjunto de datos que minimice la covarianza, lo que resulta en una representación más precisa y menos dispersa de los datos originales.




K NEAREST NEIGHBORS

- Para una observación, su distancia a su k-ésimo vecino más cercano podría considerarse como la puntuación de anomalía. Podría considerarse una forma de medir la densidad.

KNN K NEAREST NEIGHBORS (USE THE DISTANCE TO THE KTH NEAREST NEIGHBOR AS THE OUTLIER SCORE)

AVGKNN AVERAGE KNN (USE THE AVERAGE DISTANCE TO K NEAREST NEIGHBORS AS THE OUTLIER SCORE)

MEDKNN MEDIAN KNN (USE THE MEDIAN DISTANCE TO K NEAREST NEIGHBORS AS THE OUTLIER SCORE)



SI UN DATO ESTÁ MUY AISLADO
TODOS SUS VECINOS ESTARÁN LEJOS.
NO SÓLO EL PRIMERO.

Explicación — Diapositiva 3

Tema: k Nearest Neighbors - Puntuación de Anomalía basada en Distancia

Síntesis:

En el método k Nearest Neighbors (kNN), la distancia de una observación a su k-ésimo vecino más cercano puede usarse como una medida de anomalía o puntuación de anomalía. Esta puntuación se relaciona con la densidad de los datos y puede ser medido utilizando diferentes funciones de media y mediana de las distancias.

Explicación:

El k Nearest Neighbors (kNN) es un algoritmo de aprendizaje supervisado utilizado para clasificar o predecir valores de una variable dependiente. En este contexto, la idea es que una observación puede ser considerada anómala si está muy alejada de sus vecinos más cercanos. La distancia a su k-ésimo vecino más cercano se utiliza como una forma de medir esta anomalía.

Función de Anomalía Basada en Distancia

La puntuación de anomalía se obtiene al calcular la distancia de una observación a su k-ésimo vecino más cercano. Esto se puede hacer de varias maneras:

1. **Media de Distancias (AvgKNN):** Se calcula la media de todas las distancias desde la observación a sus k vecinos más cercanos. Una observación con una media de distancias alta puede ser considerada anómala.
2. **Mediana de Distancias (MedKNN):** Se calcula la mediana de las distancias desde la observación a sus k vecinos más cercanos. Una observación con una mediana de distancias alta también puede ser considerada anómala.

Conceptos Importantes

- **Vecino Más Cercano:** El vecino más cercano de una observación es el más próximo en términos de distancia. Este concepto es fundamental para calcular la puntuación de anomalía.
- **Densidad:** La puntuación de anomalía se relaciona con la densidad de los datos. En áreas densas, los vecinos más cercanos están próximos entre sí, mientras que en áreas menos densas, los vecinos más cercanos pueden estar más dispersos.

- **No Solo el Primer Vecino:** La puntuación de anomalía no se basa solo en la distancia a su primer vecino más cercano. Se considera a todos los k vecinos más cercanos.

Ejemplo

Supongamos que tenemos una observación y queremos calcular su puntuación de anomalía usando el kNN. Si el k es 3, entonces estamos considerando a los tres vecinos más cercanos. Si la distancia de nuestra observación a su tercer vecino más cercano es muy alta, podemos decir que esta observación es anómala.

Funciones de Peso

Además de la puntuación de anomalía basada en la media y mediana de las distancias, también se pueden utilizar funciones de peso basadas en las distancias. Estas funciones pueden dar más importancia a las distancias más cortas, lo que puede mejorar la precisión de la detección de anomalías.

Conclusión

En resumen, en el k Nearest Neighbors, la distancia a su k -ésimo vecino más cercano puede usarse como una puntuación de anomalía. Esta puntuación se relaciona con la densidad de los datos y puede ser medida utilizando la media o la mediana de las distancias. Este método es útil para identificar observaciones que están muy alejadas de su entorno, lo que puede indicar anomalías o outliers en el conjunto de datos.